
UNIVERSIDADE DE SÃO PAULO
INSTITUTO DE FÍSICA DE SÃO CARLOS
DEPARTAMENTO DE FÍSICA E CIÊNCIA INTERDISCIPLINAR

PROGRAMA UNIFICADO DE BOLSAS DE ESTUDO PARA APOIO À
FORMAÇÃO DE ESTUDANTES DE GRADUAÇÃO

PROCESSAMENTO DE IMAGENS POR RESSONÂNCIA MAGNÉTICA
UTILIZANDO TRANSFORMADA WAVELET

RESPONSÁVEL: PROF. DR. FERNANDO F. PAIVA

RESUMO

As imagens por Ressonância Magnética (RM) são cruciais na prática clínica devido à sua capacidade diagnóstica abrangente e não invasiva, aplicáveis a diversas partes do corpo para o diagnóstico de doenças neurológicas, cardiovasculares e oncológicas. No entanto, a qualidade dessas imagens pode ser comprometida por ruídos durante a aquisição e transmissão, necessitando de técnicas de pré-processamento. A detecção de bordas é fundamental para a segmentação de estruturas anatômicas e diferenciação entre tecidos normais e patológicos, mas métodos tradicionais apresentam limitações frente ao ruído e à complexidade de imagens de RM. A transformada wavelet é uma poderosa alternativa, oferecendo análise multi-resolução que combina componentes de frequência e localização, o que a torna ideal para detecção de características em diferentes escalas e para a preservação da precisão espacial e da frequência em imagens médicas. Este projeto de graduação visa explorar e implementar técnicas baseadas na transformada wavelet para o processamento de imagens de RM, com foco na detecção de bordas

e redução de ruído, buscando definir as configurações mais eficientes para cada caso. O trabalho será desenvolvido por dois bolsistas, atuando de forma complementar para otimizar os resultados e aprofundar a compreensão da ferramenta.

1 INTRODUÇÃO E JUSTIFICATIVA

As imagens por Ressonância Magnética (RM) são consideradas ferramentas essenciais e amplamente utilizadas em aplicações clínicas devido à sua capacidade diagnóstica abrangente e não invasiva. Elas permitem o diagnóstico e acompanhamento de inúmeras doenças, incluindo as neurológicas, cardiovasculares e oncológicas, abrangendo praticamente todas as partes do corpo humano. Para um diagnóstico preciso das características anatômicas internas, é fundamental obter imagens nítidas, de alta resolução e sem ruído.

A análise eficiente dessas imagens é crucial para a detecção precisa de anomalias e para o planejamento de tratamentos adequados. Dentro do processamento de imagens médicas, a detecção de bordas é uma técnica de fundamental importância. Ela possibilita a segmentação de diferentes estruturas anatômicas, auxiliando na identificação das fronteiras entre tecidos normais e patológicos. Contudo, a aquisição e transmissão de imagens médicas frequentemente as contaminam ou distorcem com diversos tipos de ruídos. A RM, embora altamente eficaz, sofre de deficiências como ruído do equipamento, ruído ambiente, ruído do tecido de fundo, e perturbações devido a outros órgãos e influências anatômicas como fluxo sanguíneo, gordura corporal e movimento respiratório. Métodos rápidos de RM, como o EPI, embora reduzam o tempo de investigação, resultam em baixa relação sinal-ruído (SNR) e baixo contraste. O ruído Rice, comum em imagens de

RM, é dependente do sinal e introduz um viés que reduz o contraste, sendo particularmente problemático em regimes de baixa SNR. A presença de ruído limita a eficácia do diagnóstico e pode causar perda de detalhes da imagem.

Em contraste com os métodos tradicionais de detecção de bordas, como os operadores de Sobel, Canny e Laplaciano, que são limitados pela sensibilidade ao ruído e pela dificuldade em detectar bordas em imagens complexas e de alta resolução, e as técnicas lineares de denoising (como filtragem de Wiener, mediana e Gaussiana) que podem introduzir embaçamento, a transformada wavelet surge como uma alternativa poderosa. Ela oferece uma análise multi-resolução, combinando componentes de frequência e localização, o que é particularmente útil para a detecção de características em diferentes escalas. Ao contrário da transformada de Fourier, que analisa sinais apenas em termos de suas componentes de frequência, a transformada wavelet decompõe um sinal em componentes de frequência e localização, permitindo uma análise mais detalhada e localizada. Essa característica é especialmente benéfica para a detecção de bordas em imagens médicas, onde a precisão espacial e a frequência são essenciais. A transformada wavelet também possui a capacidade de compactar bem a energia, capturando a energia de um sinal em poucos coeficientes. A aplicação da transformada wavelet para denoising de imagens de RM foi pioneira na redução de ruído sem diminuir a nitidez das bordas.

Este projeto visa estudar, implementar e avaliar técnicas baseadas na transformada wavelet para a detecção de bordas em imagens de RM. O objetivo principal é avaliar e definir as melhores configurações e estratégias para o processamento de imagens de RM utilizando wavelet, buscando compreender as vantagens e os limites de eficiência na detecção de bordas de tecidos de interesse. Espera-se entender melhor a aplicabilidade desta ferramenta e suas possíveis

contribuições para o processamento de imagens médicas. De forma específica, o projeto pretende avaliar a eficiência de diferentes funções wavelets para definir a melhor configuração para cada caso, determinar a melhor família wavelet a ser utilizada, bem como a melhor estratégia de decisão sobre o nível de truncamento e a forma de truncamento dos coeficientes, visando obter uma imagem mais bem segmentada. Este estudo busca fornecer um conhecimento mais detalhado dos desafios para uma detecção de bordas adequada em imagens de RM, a fim de definir a maneira mais eficaz de desenvolver ferramentas que auxiliem nesse propósito, afetando o mínimo possível as características originais da imagem e maximizando a seleção automatizada do tecido de interesse.

2 OBJETIVOS

O projeto será dividido entre dois bolsistas, B1 e B2, com objetivos e cronogramas complementares.

2.1 BOLSISTA 1 (B1): FUNDAMENTAÇÃO E IMPLEMENTAÇÃO DE MÉTODOS TRADICIONAIS

Estabelecer a base do projeto, implementando as transformadas wavelet, as métricas de avaliação e as técnicas de *thresholding* mais comuns com *mother wavelets* básicas.

2.1.1 OBJETIVOS ESPECÍFICOS

- **Estudo e Familiarização:** Aprofundar-se nos conceitos fundamentais da transformada wavelet (DWT) e no processamento de imagens médicas.

- **Implementação de Infraestrutura:** Desenvolver as rotinas em Python para leitura de dados (imagens de RM), realização da DWT (direta e inversa) e implementação das métricas de avaliação (SNR, PSNR, MSE, contraste, inclinação de borda)
- **Implementação de *Thresholding* Padrão:** Implementar e avaliar as técnicas de *hard thresholding* e *soft thresholding* utilizando o limiar universal (VisuShrink)
- **Avaliação de Wavelets Fundamentais:** Testar e comparar a eficiência das funções wavelet Haar e Daubechies (com ênfase em Daubechies de baixa ordem, como db2) para o denoising e detecção de bordas em diferentes níveis de decomposição.
- **Análise Comparativa Inicial:** Comparar o desempenho das técnicas de *thresholding* padrão e das *mother wavelets* básicas em imagens de RM com diferentes níveis de ruído, focando em imagens de estrutura mais simples.
- **Documentação:** Manter um registro detalhado de todas as implementações, resultados e observações.

2.2 BOLSISTA 2 (B2): EXPLORAÇÃO DE TÉCNICAS AVANÇADAS E OTIMIZAÇÃO

Construir sobre a base do B1, explorando técnicas de *thresholding* mais avançadas (adaptativas e Wiener), avaliando *mother wavelets* complexas e investigando a otimização de parâmetros para diferentes tipos de imagens de RM.

2.2.1 OBJETIVOS ESPECÍFICOS:

- **Estudo de Técnicas Avançadas:** Pesquisar e compreender conceitos de *thresholding* adaptativo (e.g., AGGD melhorado, TNN) e filtragem Wiener em domínio wavelet.
- **Implementação de *Thresholding* Avançado:** Implementar e avaliar as técnicas de *thresholding* adaptativo, como o *adaptive hard* e *adaptive soft thresholding*, e o *improved AGGD threshold*.
- **Avaliação de Wavelets Complexas:** Testar e comparar a eficiência de funções wavelet mais complexas, como Symlet, Coiflet e Discrete Meyer, em combinação com as técnicas de *thresholding*. Wavelets bi-ortogonais são destacadas por um bom equilíbrio entre inclinação de borda e SNR em todos os métodos de limiarização, sendo ótimas para imagens complicadas. Wavelets Coiflet e Symlet oferecem alto SNR à custa de menor inclinação da borda e diferem em imagens mais complexas. A wavelet Discrete Meyer é recomendada como uma *mother wavelet* universal para processar imagens complicadas, especialmente com *soft thresholding* ou filtragem Wiener.
- **Otimização de Parâmetros:** Investigar e definir as melhores configurações para o número de níveis de decomposição e as estratégias de truncamento (soft/hard thresholding com métodos *fixed-form* e *rigorous SURE*), visando a segmentação ideal.
- **Análise Comparativa Aprofundada:** Realizar uma análise comparativa detalhada dos resultados obtidos, considerando a escolha da *mother wavelet* em conjunto com a técnica de *thresholding* para diferentes tipos de imagens de RM (simples vs. complexas, baixo vs. alto SNR).

3 METODOLOGIA

O projeto será implementado em Python, aproveitando sua natureza de código aberto e suas bibliotecas especializadas. As principais bibliotecas a serem utilizadas incluem NumPy, SciPy, Matplotlib e PyWavelets.

A Transformada Wavelet Discreta (DWT) será a técnica central. Ela decompõe uma imagem em aproximações de baixa frequência (componentes de alta escala e baixa frequência) e detalhes de alta frequência (componentes de baixa escala e alta frequência)¹³¹⁴. As informações de borda concentram-se nos componentes de alta frequência.

O processo de denoising em domínio wavelet envolve a aplicação de um limiar (*thresholding*) aos coeficientes wavelet. Coeficientes com valores abaixo de um determinado limiar são considerados ruído e podem ser cancelados. As principais técnicas de *thresholding* são *hard* e *soft thresholding*.

- **Hard Thresholding:** Mantém os coeficientes inalterados se seus valores absolutos forem maiores ou iguais ao limiar (T), e os zera se forem menores que T . É conhecido por preservar melhor a inclinação da borda, mas pode resultar em menor SNR e introduzir descontinuidades.
- **Soft Thresholding:** Reduz os coeficientes em T (mantendo o sinal) se seus valores absolutos forem maiores ou iguais a T , e os zera se forem menores que T . Geralmente produz um SNR melhor, mas pode reduzir a nitidez da imagem (borramento).

A escolha da *mother wavelet* e da técnica de *thresholding* são aspectos cruciais para a qualidade do denoising. Múltiplas *mother wavelets* (e.g., Haar, Daubechies,

Symlet, Morlet, Meyer) serão investigadas, pois cada uma pode ser mais adequada para diferentes tipos de imagens e objetivos.

3.1 TRANSFORMADA WAVELET DISCRETA

A Transformada Wavelet Discreta (DWT, do inglês *Discrete Wavelet Transform*) de uma função (que pode ser um sinal ou uma imagem) produz uma representação não redundante que fornece informação acerca da localização espacial e espectral da formação dessa função. A DWT pode ser interpretada como uma decomposição em um conjunto de canais de frequência independentes e espacialmente orientados. O sinal passa por dois filtros complementares e emerge como dois sinais: aproximação e detalhes. Os componentes podem, então, ser montados de volta no sinal original sem perda de informações através da transformada inversa.

Devido à possibilidade de decompor as funções tanto no domínio da frequência quanto no domínio do tempo, as funções wavelets são ferramentas poderosas de processamento de sinais. Um sinal analisado pela DWT é dividido em duas componentes: as aproximações (A) que são componentes de alta escala e baixa frequência, e os detalhes (D) que são componentes de baixa escala e alta frequência, conforme ilustrado na Figura 1.




Figura 01: Árvore ou encadeamento da Decomposição de Wavelet.

A DWT opera sobre o sinal meio de um algoritmo iterativo. Assim, a decomposição do sinal original é realizada em sub-bandas, que correspondem às componentes do sinal original em diferentes faixas de frequências. Uma segunda decomposição pode ser efetuada sobre a primeira aproximação gerada, e assim sucessivamente. Este processo é chamado de árvore de decomposição Wavelet ou encadeamento, e está representado na Figura 1. A cada encadeamento, a frequência de amostragem é dividida por 2.

As informações sobre as bordas dos tecidos de interesse devem se concentrar nas componentes de alta frequência da decomposição. Dessa forma, esses são os coeficientes que precisam ser ajustados quando esta aplicação é o principal foco do processamento (D & D, 2011; Kaur & Kaur, 2012).

4 RESULTADOS ESPERADOS E INDICADORES DE ACOMPANHAMENTO

A colaboração entre os dois bolsistas será fundamental. B1 fornecerá a infraestrutura básica e os resultados de referência, enquanto B2 aprofundará as técnicas e buscará otimizações, com ambos contribuindo para a análise e escrita do relatório final. Espera-se que este projeto forneça um conhecimento detalhado dos desafios na detecção de bordas e redução de ruído em imagens de RM usando transformada wavelet, permitindo definir a melhor forma de desenvolver ferramentas que auxiliem no diagnóstico, maximizando a seleção do tecido de interesse de maneira automatizada e afetando minimamente as características originais da imagem. Os resultados podem incluir a identificação de combinações ótimas de *mother wavelets* e métodos de *thresholding* para cenários específicos de imagens de RM (e.g., imagens com alto/baixo SNR, imagens com estruturas simples/complexas).

Os principais resultados do presente trabalho serão apresentados nos eventos internos da USP e, dependendo da disponibilidade, em eventos científicos da área de ressonância magnética.

5 CRONOGRAMAS DE EXECUÇÃO

O trabalho proposto foi dividido em etapas gerais, a serem executadas pelos bolsistas de forma complementar.

5.1 BOLSISTA 1 (B1)

- Etapa I: Estudo e Familiarização: Revisão bibliográfica sobre Transformada Wavelet (DWT, propriedades), processamento de imagens médicas e denoising. Configuração do ambiente Python e bibliotecas.
- Etapa II: Implementação de Infraestrutura: Funções para leitura de imagens (DICOM ou outros formatos de RM), implementação da DWT direta e inversa. Implementação das métricas de avaliação (SNR, PSNR, MSE, Contraste, Inclinação de Borda).
- Etapa III: Implementação e Avaliação de Thresholding Padrão: Implementação de hard e soft thresholding. Definição do limiar universal (VisuShrink). Testes iniciais com wavelets Haar e Daubechies (ex: db2) em imagens.
- Etapa IV: Análise Comparativa: Comparação dos resultados das wavelets e métodos de thresholding implementados.
- Etapa V: Redação dos relatórios;

Etapas	Trimestre			
	1	2	3	4
I	X			
II	X	X		
III		X	X	
IV		X	X	X
V		X		X

5.2 BOLSISTA 2 (B2)

- Etapa I: Estudo de Técnicas Avançadas: Revisão bibliográfica sobre thresholding adaptativo (AGGD, TNN), filtragem Wiener em domínio wavelet e avaliação de mother wavelets avançadas.
- Etapa II: Implementação de Thresholding Avançado: Implementação de adaptive hard e adaptive soft thresholding. Implementação do improved AGGD threshold.
- Etapa III: Avaliação de Wavelets Complexas e Otimização: Testes com wavelets Symlet, Coiflet e Discrete Meyer. Avaliação dos efeitos de diferentes níveis de detalhamento e estratégias de truncamento (fixed-form e rigorous SURE).
- Etapa IV: Análise Comparativa: Comparação das técnicas avançadas com os resultados de B1 e entre si, focando na aplicabilidade para diferentes tipos de imagens de RM (estrutura complexa, baixo SNR).
- Etapa V: Redação dos relatórios;

Etapas	Trimestre			
	1	2	3	4
I	X			
II	X	X		
III		X	X	
IV		X	X	X
V		X		X

6 REFERÊNCIAS

- Alexander, M. E., Baumgartner, R., Summers, A. R., Windischberger, C., Klarhoefer, M., Moser, E., & Somorjai, R. L. (2000). A wavelet-based method for improving signal-to-noise ratio and contrast in MR images. *Magnetic Resonance Imaging*, 18(2), 169–180. [https://doi.org/10.1016/S0730-725X\(99\)00128-9](https://doi.org/10.1016/S0730-725X(99)00128-9)
- Brown, R. W., Cheng, Y. C. N., Haacke, E. M., Thompson, M. R., & Venkatesan, R. (2014). Magnetic Resonance Imaging: Physical Principles and Sequence Design: Second Edition. In *Magnetic Resonance Imaging: Physical Principles and Sequence Design: Second Edition* (Vol. 9780471720850). <https://doi.org/10.1002/9781118633953>
- D, S., & D, D. (2011). Wavelet Based Image Denoising Technique. *International Journal of Advanced Computer Science and Applications*, 2(3), 49–53. <https://doi.org/10.14569/ijacsa.2011.020309>
- Kaur, G., & Kaur, R. (2012). *IMAGE DE-NOISING USING WAVELET TRANSFORM*. 2(2), 15–21.
- Mallat, S. (2009). *A Wavelet Tour of Signal Processing: The Sparse Way* (Vol. 1). Elsevier. <http://elsevier.com>
- Nowak, R. D. (1999). Wavelet-based Rician noise removal for magnetic resonance imaging. *IEEE Transactions on Image Processing*, 8(10), 1408–1419. <https://doi.org/10.1109/83.791966>