

Universidade de São Paulo



Relatório 2

Iniciação Científica

Processamento de Imagens por
Ressonância Magnética Utilizando
Transformada Wavelet

Aluno: Thiago Oliveira dos Santos
Orientador: Fernando Fernandes Paiva

São Carlos

2025

Sumário

Resumo	2
1 Objetivos	3
2 Introdução	3
3 Base Teórica	4
3.1 Considerações Sobre Imagens Digitais	4
3.2 Revisão de Transformadas Wavelet e de Fourier	5
3.3 Ruído e SNR	8
3.4 Técnicas de Thresholding	10
4 Metodologia	11
4.1 Implementação Inicial	11
4.2 Filtragem por Wavelet Visual	12
4.3 Pipeline e Coleta de Dados	18
4.4 Repositório Online	20
5 Resultados	20
6 Conclusão	23
Referências Bibliográficas	26

Resumo

Este relatório apresenta o desenvolvimento de um projeto de iniciação científica voltado ao processamento de imagens por Ressonância Magnética (RM) utilizando Transformada Wavelet (WT).

Inicialmente, o trabalho concentrou-se no estudo de conceitos fundamentais do processamento digital de sinais, incluindo a digitalização segundo o Teorema de Nyquist, a Transformada de Fourier (FT), a WT, a caracterização do ruído em sinais e métricas de qualidade, e as técnicas de limiarização (thresholding).

Em paralelo, foram propostas implementações em Python [1] com uso das bibliotecas *NumPy* [2], *Matplotlib* [3] e *PyWavelets* [4], que culminaram na criação de rotinas para simulação de sinais unidimensionais, leitura de sinais, aplicação da FT e WT, adição de ruído, cálculo de métricas de avaliação, e aplicação de thresholding.

Os experimentos realizados envolveram a aplicação da Transformada Wavelet Bidimensional (WT-2D) em uma imagem de RM corrompida por ruído gaussiano, testando diferentes famílias wavelet (Haar, Daubechies-2 (db2), Symlet-2 (sym2) e Coiflet-1 (coif1)) e métodos de thresholding (hard e soft), utilizando como limiar de corte o limiar universal definido pela VisuShrink.

Os resultados indicaram que o hard thresholding apresentou maior ganho de Razão Sinal-Ruído (SNR) em comparação ao soft thresholding, embora este último preserve melhor detalhes visuais, enquanto a família Haar mostrou desempenho inferior às demais.

Este relatório reúne a base teórica desenvolvida, a descrição do software implementado e a análise dos resultados obtidos, destacando a viabilidade do uso de wavelets para redução de ruído em imagens médicas.

1 Objetivos

O objetivo principal deste projeto é avaliar a eficácia da Transformada Wavelet na redução de ruído em imagens de Ressonância Magnética, considerando a preservação de bordas e detalhes estruturais.

Para alcançar esse objetivo, foram definidos os seguintes objetivos específicos:

- Estudar os conceitos fundamentais do processamento de imagens e das transformadas matemáticas relevantes.
- Implementar e analisar a FT para sinais unidimensionais (1D) e bidimensionais (2D), como etapa de fundamentação.
- Implementar a WT para sinais 1D, explorando técnicas iniciais de denoising por limiarização de forma visual e qualitativa.
- Implementar a WT-2D em imagens, aplicando 2 técnicas de thresholding diferentes junto do método VisuShrink, com comparação entre diferentes famílias wavelet.
- Realizar experimentos controlados com uma imagem de RM corrompida por ruído gaussiano com desvio padrão variável, coletar métricas quantitativas de desempenho e analisar os resultados por meio de gráficos.

2 Introdução

A RM é uma técnica amplamente utilizada na física médica para a detecção de doenças e alterações em tecidos de forma não invasiva [5]. Este projeto considera tanto a Espectroscopia por Ressonância Magnética (ERM), que fornece sinais 1D, quanto o Imageamento por Ressonância Magnética (IRM), que gera sinais 2D (imagens), como objetos de estudo.

Entretanto, limitações experimentais, como a necessidade de exames rápidos e a presença de ruído associado à instrumentação e ao metabolismo do paciente, resultam em sinais degradados, dificultando sua análise e interpretação diagnóstica [6]. Para contornar esse problema, diversas técnicas de processamento de sinais vêm sendo aplicadas para realçar a qualidade dos dados.

Contudo, abordagens tradicionais, como a filtragem baseada na FT, não são ideais quando é necessário preservar bordas e detalhes finos [7]. Nesse contexto, este projeto explora a aplicação da WT, cuja versatilidade permite analisar sinais simultaneamente nos domínios do tempo e da frequência, oferecendo uma alternativa promissora para a redução de ruído em imagens de RM [8].

3 Base Teórica

Nesta seção são apresentados os conceitos fundamentais que embasam o desenvolvimento deste trabalho. São abordados princípios de imagens digitais, as transformadas de Fourier e Wavelet, os principais modelos de ruído em sinais de RM e a métrica de SNR, além de técnicas de thresholding aplicadas à redução de ruído. O estudo desses tópicos foi essencial para a implementação das rotinas em Python e para a análise crítica dos resultados obtidos.

3.1 Considerações Sobre Imagens Digitais

No escopo deste projeto, trabalhamos apenas com sinais digitais. Diferentemente dos sinais analógicos, os sinais digitais são discretos, o que permite seu processamento por ferramentas computacionais [9]. Nesse sentido, uma imagem digital pode ser representada como uma função $f(x, y)$, em que x e y são variáveis discretas inteiras que identificam as coordenadas de cada pixel; para cada par (x, y) , a função retorna um valor correspondente à intensidade luminosa naquela posição [10].

No contexto do processamento de imagens, o impacto do uso de sinais digitais se dá pela possibilidade de manipulá-los por meio de sistemas, como ilustrado na Figura 1. Um sistema pode ser descrito genericamente como uma aplicação $S : X \rightarrow Y$, que transforma um sinal de entrada em um sinal de saída, não necessariamente definidos sobre o mesmo domínio e contradomínio.




Figura 1: Esquema do funcionamento de um sistema.
Fonte: Higuti e Kitano (2003)

Exemplos de sistemas $S\{\cdot\}$ utilizados em processamento digital de sinais incluem a Transformada de Fourier $\mathcal{F}\{\cdot\}$ e a Transformada Wavelet $\langle f, \psi_{a,b} \rangle$, que

geram novas representações a partir do sinal original. Essas representações podem facilitar a extração de informações específicas, como componentes espectrais ou localizações temporais. Além disso, a convolução com filtros passa-baixas e passa-altas também pode ser interpretada como a aplicação de sistemas, permitindo destacar características relevantes do sinal processado [7].

3.2 Revisão de Transformadas Wavelet e de Fourier

No processamento digital de sinais, as transformadas matemáticas desempenham papel essencial na representação e análise de informações que não são facilmente observáveis no domínio do tempo ou do espaço [9]. Entre elas, destacam-se a FT e a WT, utilizadas neste projeto para caracterização espectral e redução de ruído em sinais e imagens.

A **Transformada de Fourier** permite decompor um sinal em combinações de funções harmônicas senoidais e cossenoidais. Sua formulação contínua é dada por:

$$F(\omega) = \int_{-\infty}^{\infty} f(t)e^{-i\omega t} dt \quad (1)$$

em que $f(t)$ representa o sinal no tempo e $F(\omega)$ representa sua versão no domínio da frequência [12]. Essa transformada é útil na identificação de componentes espectrais e na análise global do conteúdo de frequências de um sinal. Entretanto, sua principal limitação é a ausência de informação temporal: ao realizar a transformação, perde-se a localização exata de cada frequência no tempo [13].

Contudo, ao trabalharmos com sinais digitais, é inviável utilizar a FT em seu formato contínuo, pois isso implicaria realizar uma quantidade infinita de operações para calcular os componentes espectrais [9]. Para solucionar esse problema, aplica-se a Transformada de Fourier Discreta (DFT), que pode ser eficientemente calculada pelo algoritmo da Transformada Rápida de Fourier (FFT) [14]. A Figura 2 ilustra essa limitação, mostrando um sinal de eletrocardiograma (ECG) (acima) no tempo e sua DFT (abaixo), onde a informação temporal é perdida.

Para contornar essa limitação, surgiram abordagens que conciliam análise temporal e espectral. A mais versátil entre elas é a **Transformada Wavelet**, que representa um sinal a partir de funções oscilatórias localizadas, chamadas wavelets. Diferentemente da FT, a WT oferece uma análise multirresolução, identificando simultaneamente em quais intervalos de tempo determinadas frequências estão presentes. Sua formulação contínua pode ser expressa como:

$$W(a, b) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{\infty} f(t) \psi\left(\frac{t-b}{a}\right) dt, \quad (2)$$

em que a é o parâmetro de escala, b é o parâmetro de translação, e $\psi(t)$ é a função





Figura 2: Exemplo de um sinal de ECG e sua FT.
Fonte: Fachine, 2010

wavelet mãe [16].


Na prática, utiliza-se a **Transformada Wavelet Discreta** (DWT), uma vez que não é possível calcular toda a continuidade do espectro [16]. A DWT é efetivamente calculada por meio de filtros passa-baixas e passa-altas e implementada pelo Algoritmo de Mallat [12, 13, 17]. Essa decomposição gera aproximações (componentes de baixa frequência) e detalhes (componentes de alta frequência), permitindo análise em diferentes níveis de resolução [16]. Essa abordagem hierárquica é particularmente útil em aplicações de compressão de dados e redução de ruído, pois possibilita manipular seletivamente os coeficientes associados a ruído de alta frequência [6].

Esses comportamentos da WT podem ser observados na Figura 3. Na Figura 3a temos um sinal sintético composto por duas frequências: uma de 300 Hz, que decai rapidamente, e outra de 850 Hz, que decai mais lentamente. Note na Figura 3b como a FT mostra globalmente as frequências presentes, mas sem indicar quando ocorrem no tempo. Já a Figura 3c mostra como a abordagem multirresolução da DWT permite identificar tanto a persistência de uma frequência entre 500–1000 Hz durante todo o sinal, quanto a presença de outra componente de frequência,

localizada nos níveis 2 e 3, que aparece apenas no início e decai rapidamente.



(a) Sinal sintético composto por duas frequências com tempos de relaxação distintos. (b) Perda de caracterização temporal na FT.




(c) Caracterização temporal obtida com a WT.

Figura 3: Sinal simulado e suas transformadas.


Em síntese, enquanto a FT fornece uma visão global do espectro, a WT oferece uma análise conjunta tempo-frequência, sendo mais adequada em situações em que há variações locais importantes, como é o caso de sinais biomédicos de RM. Essa característica torna a WT uma ferramenta promissora para técnicas de denoising, pois permite atenuar ruídos preservando detalhes relevantes, como bordas.

No caso de imagens bidimensionais, aplica-se a **Transformada Wavelet 2D** (WT-2D). Nessa abordagem, o processo de filtragem é realizado separadamente nas linhas e colunas da matriz da imagem, resultando em quatro sub-bandas por nível de decomposição: aproximações (LL), detalhes horizontais (LH), detalhes

verticais (HL) e detalhes diagonais (HH). Esse procedimento pode ser repetido recursivamente sobre a sub-banda de aproximações, permitindo uma análise em múltiplos níveis de resolução. A WT-2D é especialmente adequada para imagens médicas, pois permite destacar bordas e estruturas relevantes ao mesmo tempo em que concentra grande parte do ruído nas bandas de alta frequência, onde pode ser atenuado seletivamente por técnicas de thresholding [18, 17]. A Figura 4 mostra um exemplo de sinal transformado por WT-2D até o nível 2 utilizando a família Daubechies-2 em seus diferentes níveis.



(a) Nível 1 da WT-2D de uma imagem.



(b) Nível 2 da WT-2D de uma imagem.

Figura 4: Exemplo da multirresolução em um sinal transformado por WT-2D.

3.3 Ruído e SNR

Em Ressonância Magnética, os sinais adquiridos são originalmente **complexos**, compostos por uma parte real (I) e uma parte imaginária (Q) [19]. Esse sinal pode ser representado genericamente como:

$$s = s_{\text{real}} + i s_{\text{imag}} = (x_{\text{real}} + n_{\text{real}}) + i(x_{\text{imag}} + n_{\text{imag}}), \quad (3)$$

onde x corresponde ao sinal verdadeiro e n ao ruído, ambos com componentes real e imaginária [6]. Assumindo que o ruído é gaussiano, de média zero e variância σ^2 , cada componente n_{real} e n_{imag} segue uma distribuição normal independente:

$$n_{\text{real}}, n_{\text{imag}} \sim \mathcal{N}(0, \sigma^2). \quad (4)$$

Neste domínio complexo, o modelo de ruído reduz-se a dois **ruídos gaussiano branco aditivo** (AWGN) [19]. No entanto, em diversas aplicações, o sinal de RM é representado a partir de sua **magnitude**:

$$r = |s| = \sqrt{(x_{\text{real}} + n_{\text{real}})^2 + (x_{\text{imag}} + n_{\text{imag}})^2}. \quad (5)$$

Nesse caso, a natureza estatística do ruído se modifica. A distribuição de r depende da relação entre a amplitude do sinal verdadeiro $A = \sqrt{x_{\text{real}}^2 + x_{\text{imag}}^2}$ e o desvio padrão σ do ruído [6]:

- Quando não há sinal ($A = 0$), o valor de r segue uma **distribuição de Rayleigh**:

$$p(r) = \frac{r}{\sigma^2} e^{-\frac{r^2}{2\sigma^2}}, \quad r \geq 0. \quad (6)$$

- Quando o sinal é não nulo ($A > 0$), o valor de r segue uma **distribuição Rician**:

$$p(r) = \frac{r}{\sigma^2} \exp\left(-\frac{r^2 + A^2}{2\sigma^2}\right) I_0\left(\frac{Ar}{\sigma^2}\right), \quad r \geq 0, \quad (7)$$

onde $I_0(\cdot)$ é a função de Bessel modificada de primeira espécie e ordem zero.

A distribuição Rician tende à Rayleigh quando $A \rightarrow 0$ (na ausência de sinal, como no fundo de uma imagem) e aproxima-se da Gaussiana quando $A \gg \sigma$. Essas diferenças têm impacto direto nas técnicas de filtragem: métodos otimizados para ruído gaussiano podem apresentar limitações quando aplicados a imagens de magnitude [6]. No escopo deste projeto, o foco recai sobre regiões dominadas por ruído, de modo que não se considera explicitamente o modelo Rician.

A qualidade dos sinais e imagens processados é avaliada pela métrica da SNR, definida como:

$$\text{SNR} = 10 \log_{10} \left(\frac{P_{\text{sinal}}}{P_{\text{ruído}}} \right) [\text{dB}], \quad (8)$$

onde P_{sinal} e $P_{\text{ruído}}$ são as potências médias do sinal e do ruído, respectivamente. A potência média é calculada como:

$$P(s) = \frac{1}{N} \sum_{n=0}^N |s[n]|^2 = \frac{1}{N} \sum_{n=0}^N r[n]^2. \quad (9)$$

Sabe-se que a potência média de um ruído Gaussiano é igual à variância σ^2 , enquanto no caso do ruído Rayleigh a potência média corresponde a $2\sigma^2$ [6, 19].

3.4 Técnicas de Thresholding

Um dos grandes diferenciais da Transformada Wavelet é a possibilidade de aplicar técnicas de **limiarização** (*thresholding*) diretamente sobre seus coeficientes [20]. Esse procedimento consiste em modificar os coeficientes de detalhe da decomposição wavelet de forma a reduzir ou eliminar aqueles associados majoritariamente ao ruído, preservando os relacionados ao sinal de interesse [13].

A limiarização pode ser aplicada segundo diferentes estratégias, das quais se destacam [21]:

- **Hard thresholding:** todos os coeficientes cujo módulo é inferior a um valor de corte λ são reduzidos a zero, enquanto os demais permanecem inalterados. Formalmente:

$$w' = \begin{cases} 0, & |w| < \lambda \\ w, & |w| \geq \lambda \end{cases} \quad (10)$$

onde w são os coeficientes originais e w' os coeficientes limiarizados. Essa abordagem promove maior ganho de SNR, mas pode introduzir descontinuidades no sinal reconstruído, perceptíveis como artefatos.

- **Soft thresholding:** neste caso, os coeficientes abaixo do limiar λ também são anulados, mas os coeficientes acima do limiar são reduzidos em magnitude, aproximando-os de zero:

$$w' = \begin{cases} 0, & |w| < \lambda \\ \text{sgn}(w)(|w| - \lambda), & |w| \geq \lambda \end{cases} \quad (11)$$

O resultado é um processamento mais suave, com menor ganho de SNR em comparação ao *hard thresholding*, mas com melhor preservação de bordas e detalhes finos.

A escolha do valor do limiar λ é fundamental para o desempenho do método. Uma das abordagens mais utilizadas é o **VisuShrink**, proposto por Donoho e Johnstone [22], em que o limiar universal é calculado como:

$$\lambda = \sigma \sqrt{2 \log N}, \quad (12)$$

onde N é o número de amostras do sinal e σ é o desvio padrão do ruído estimado. Esse método fornece um valor de corte adaptado ao tamanho da amostra, garantindo que a maior parte do ruído seja eliminada.

Na prática, técnicas de thresholding baseadas em wavelets têm demonstrado grande eficiência na redução de ruído em imagens médicas, incluindo RM, pois

permitem atenuar o ruído sem comprometer significativamente as estruturas anatômicas de interesse. Assim, a aplicação criteriosa dessas estratégias constitui um dos pilares do presente projeto.

4 Metodologia

Nesta seção, são descritos os procedimentos adotados para o desenvolvimento dos programas, a realização dos experimentos e a coleta dos dados. Todos os códigos foram implementados em Python, utilizando as bibliotecas *NumPy* (operações numéricas e matriciais), *Matplotlib* (visualização gráfica), *PyWavelets* (transformadas wavelet), *Pandas* [23] (manipulação de dados tabulares) e *Seaborn* [24] (análise estatística e visualização).

4.1 Implementação Inicial

Como etapa de fundamentação, foram implementadas subrotinas capazes de:

- Gerar sinais 1D sintéticos de ERM.
- Ler e visualizar sinais 1D e 2D.
- Aplicar a FT e representar os resultados no domínio da frequência.

A estrutura do código foi organizada em três arquivos principais:

- `main.py`: programa principal em formato de interface de linha de comando (CLI), que permite ao usuário manipular sinais e operações.
- `useful.lib.py`: biblioteca desenvolvida para processar sinais e imagens, centralizando as funções matemáticas e de processamento.
- `my_image.lib.py`: biblioteca auxiliar, inicialmente desenvolvida na disciplina de Processamento e Análise de Imagens, dedicada ao tratamento específico de imagens e integração com a `useful.lib`.

A geração de sinais unidimensionais baseou-se no modelo de decaimento exponencial amortecido, com oscilação harmônica:

$$S(t) = S_0 e^{-\frac{t}{T}} e^{i\omega t} \quad (13)$$

em que T é o tempo de relaxação, ω a frequência angular em rad/s, e S_0 a amplitude inicial. O programa permite a geração e soma de diversos sinais de frequência única, possibilitando a simulação de sinais espectrais complexos.

Para validar essa implementação, os sinais simulados foram comparados qualitativamente com resultados obtidos na dissertação de Menezes [25], considerando

parâmetros de sinais *in vivo*. A FT foi aplicada, com representação em partes por milhão (ppm), como mostrado na Figura 5, onde se observa a semelhança entre os sinais simulados e os apresentados por Menezes, confirmando a correta implementação das rotinas.




Figura 5: FT de sinal simulado com base em parâmetros de ERM *in vivo*.

4.2 Filtragem por Wavelet Visual


Após a validação das subrotinas essenciais, foram implementados recursos para:

- Corromper sinais com AWGN de acordo com a SNR desejada.
- Aplicar a WT em sinais 1D e 2D.
- Realizar uma etapa exploratória de denoising por limiarização visual em sinais 1D.
- Calcular o resíduo espectral após o denoising.


Na etapa exploratória, define-se uma coordenada de corte c ao longo do eixo horizontal de um nível específico da WT. A partir dessa coordenada, os coeficientes correspondentes são anulados. O valor de c é então variado desde uma região dominada por ruído até a região de suporte do sinal, permitindo inspecionar de forma qualitativa os efeitos do corte sobre a supressão de ruído e a preservação da forma do sinal.

Como estudo de caso, um sinal senoidal, limitado por exponencial decrescente, de


frequência única $\omega = 300$ foi corrompido por AWGN com desvio padrão $\sigma = 0.05$. As Figuras 6a–d apresentam o sinal original e o sinal corrompido, bem como suas respectivas FTs.




(a) Sinal original.



(b) Sinal corrompido.




(c) FT do sinal original.




(d) FT do sinal corrompido.

Figura 6: Sinal original, sinal corrompido por AWGN ($\sigma = 0,05$) e respectivas FTs.


Em seguida, aplicou-se a WT e, aqui mostrando por brevidade o processo apenas para o nível 2 da decomposição, variou-se o corte c para observar qualitativamente o impacto da limiarização sobre os coeficientes (Figura 7) e, na sequência, sobre o sinal reconstruído no domínio do tempo via transformada inversa (Figura 8). Por fim, avaliou-se o resíduo espectral para cada valor de c (Figura 9) e inspecionaram-se as FTs dos sinais filtrados (Figura 10).




(a) WT do sinal corrompido.




(b) Limiarização visual com corte $c = 100$.




(c) Limiarização visual com corte $c = 75$.



(d) Limiarização visual com corte $c = 50$.




(e) Limiarização visual com corte $c = 25$.




(f) Limiarização visual com corte $c = 0$.


Figura 7: Limiarização visual em WT (nível 2) com corte c variável, partindo de região dominada por ruído até a região de suporte do sinal.




(a) Sinal corrompido (referência para comparação).




(b) Sinal reconstruído após corte $c = 100$.




(c) Sinal reconstruído após corte $c = 75$.



(d) Sinal reconstruído após corte $c = 50$.




(e) Sinal reconstruído após corte $c = 25$.




(f) Sinal reconstruído após corte $c = 0$.


Figura 8: Sinais reconstruídos no domínio do tempo após limiarização visual em WT (nível 2) com diferentes valores de corte c .




(a) Resíduo espectral para $c = 100$.




(b) Resíduo espectral para $c = 75$.



(c) Resíduo espectral para $c = 50$.




(d) Resíduo espectral para $c = 25$.




(e) Resíduo espectral para $c = 0$.


Figura 9: Resíduo espectral dos sinais após limiarização visual por WT (nível 2) para diferentes cortes c .




(a) FT do sinal reconstruído após corte $c = 100$.




(b) FT do sinal reconstruído após corte $c = 75$.



(c) FT do sinal reconstruído após corte $c = 50$.




(d) FT do sinal reconstruído após corte $c = 25$.




(e) FT do sinal reconstruído após corte $c = 0$.

Figura 10: FTs dos sinais reconstruídos após limiarização visual por WT (nível 2) com diferentes cortes c .


Observa-se que, à medida que o corte avança para dentro da região de suporte do sinal, a filtragem passa a suprimir componentes relevantes, distorcendo a forma do sinal no tempo (este passa a ser moldado pela função wavelet) e introduzindo componentes externos no domínio da frequência. Essa tendência é visível tanto no crescimento do resíduo espectral quanto na alteração das FTs.




(a) Limiarização visual por WT sem invadir a região do sinal.



(b) Sinal filtrado.



(c) Resíduo espectral do sinal filtrado.



(d) FT do sinal filtrado.

Figura 11: Processo de filtragem visual.

Portanto, nessa etapa qualitativa, a filtragem visual deve limitar-se a valores de c que removam predominantemente coeficientes associados ao ruído, evitando a invasão do suporte do sinal. Assim, como mostra o procedimento da Figura 11, é possível filtrar visualmente um sinal, removendo todos os coeficientes de sua WT que representam somente ruído.


4.3 Pipeline e Coleta de Dados

Para organizar o processo experimental, foi estruturado um *pipeline* que padroniza as etapas de processamento. O fluxo de execução consiste em:


1. Leitura ou geração do sinal de entrada.
2. Degradação do sinal com SNR desejada.
3. Aplicação da WT.
4. Limiarização dos coeficientes (hard ou soft thresholding).
5. Reconstrução do sinal por meio da transformada inversa.

6. Cálculo das métricas de desempenho, como o ganho de SNR.


A Figura 12 ilustra um exemplo simplificado da aplicação do **hard thresholding** em um sinal unidimensional corrompido por AWGN. Nota-se que, após a limiarização e reconstrução, o sinal recupera parte de sua estrutura original, com redução significativa do ruído de alta frequência.




(a) Sinal original.




(b) Sinal corrompido.



(c) WT do sinal corrompido.



(d) WT do sinal corrompido após limiarização.



(e) Sinal filtrado.

Figura 12: Pipeline exemplificado para denoising de Sinal 1D por wavelets utilizando hard thresholding.

Esse mesmo procedimento foi automatizado para um grande conjunto de experimentos, variando-se o nível de ruído de entrada de 7.5 dB a 20 dB, a família wavelet utilizada e o método de thresholding. Os resultados foram armazenados em uma base de dados, posteriormente analisada por meio das bibliotecas *Pandas* e *Seaborn*, o que permitiu gerar as estatísticas e gráficos apresentados na Seção 5.

4.4 Repositório Online

Durante o desenvolvimento do projeto, foi mantido um repositório online em *GitHub*, utilizado para organizar e centralizar todos os materiais produzidos. Esse repositório contém os códigos-fonte em Python responsáveis pela implementação das rotinas descritas na metodologia, além dos scripts usados para a geração dos gráficos e análises apresentadas neste relatório.

Também estão incluídos relatórios parciais, apresentações (como a exploração inicial de limiarização visual) e arquivos auxiliares, como as referências bibliográficas utilizadas e uma revisão teórica elaborada previamente na disciplina de Processamento e Análise de Imagens.


O repositório foi estruturado de forma a garantir a reprodutibilidade do trabalho, contando com arquivos `README.md` em diretórios-chave que documentam a função de cada conjunto de códigos e materiais, e pode ser acessado por meio do seguinte link:

<https://github.com/tubar02/Transformada-Wavelet>


Dessa maneira, todo o processo — desde a fundamentação até a análise final dos resultados — pode ser rastreado e reproduzido por outros pesquisadores ou interessados.

5 Resultados


Os experimentos realizados permitiram avaliar a eficácia da WT na redução de ruído em imagens de RM. Para tal, uma imagem de RM de caso-teste, presente na Figura 13 junto com sua WT, foi corrompida por ruído AWGN em diferentes níveis de SNR de entrada, e processada por meio da WT-2D. Foram testadas quatro famílias wavelet — Haar, db2, sym2 e coif1 — em combinação com dois métodos de limiarização: hard thresholding e soft thresholding. O limiar de corte utilizado foi o limiar universal proposto pelo método VisuShrink, calculado a partir da variância do ruído.



(a) Imagem de MRI utilizada como caso-teste.



(b) Nível 1 da WT-2D da imagem original.



(c) Nível 2 da WT-2D da imagem original.

Figura 13: Imagem original e WT-2D aplicada até o nível 2.

Os resultados quantitativos foram organizados em uma base de dados e analisados por meio de um gráfico boxplot e um de dispersão, respectivamente mostrados nas Figuras 14 e 15, que ilustram a relação entre o SNR de entrada e o SNR de saída das imagens reconstruídas, bem como a distribuição do ganho de SNR em função da família wavelet e do método de thresholding.




Figura 14: Boxplot do ganho de SNR por família.




Figura 15: Gráfico de dispersão que compara SNR de entrada a SNR de saída.

De modo geral, observou-se que o **hard thresholding** apresentou maior ganho médio de SNR em comparação ao soft thresholding. Esse comportamento é esperado, uma vez que o hard thresholding zera completamente os coeficientes abaixo do limiar, eliminando de forma mais agressiva o ruído. Entretanto, essa mesma característica pode levar à perda de detalhes finos da imagem. Já o **soft thresholding**, apesar de resultar em ganhos de SNR mais modestos, mostrou-se mais eficiente na preservação de bordas e detalhes estruturais, sendo visualmente

mais adequado em determinados cenários. Essas observações são perceptíveis pela Figura 16.

Entre as famílias wavelet avaliadas, a **Haar** apresentou desempenho inferior, com menores ganhos de SNR e maior distorção visual. Esse resultado é coerente com a simplicidade dessa wavelet, que pode ser considerada como a versão mais elementar da família Daubechies. Por outro lado, as famílias **db2**, **sym2** e **coif1** mostraram desempenhos mais estáveis, com ganhos de SNR consistentes ao longo dos diferentes níveis de ruído testados.

Um aspecto adicional relevante observado na Figura 15 é que as retas de tendência ajustadas aos pontos de dispersão interceptam a reta identidade ($y = x$) em determinado valor de SNR de entrada. Essa interseção indica um limite prático: a partir desse ponto, os métodos de limiarização deixam de aumentar a SNR e passam a reduzi-la. Em outras palavras, quando o sinal já apresenta alta qualidade inicial, a aplicação de thresholding pode introduzir distorções que superam a atenuação do ruído. Esse resultado reforça que o uso da WT com thresholding é mais vantajoso em cenários de baixo SNR, enquanto em imagens de melhor qualidade deve ser empregado com cautela, priorizando a preservação de detalhes visuais em detrimento do ganho numérico de SNR.

Para ilustrar qualitativamente esses comportamentos, a Figura 16 apresenta um exemplo de denoising em imagem corrompida com SNR de entrada de 15 dB, comparando os resultados obtidos por hard e soft thresholding.


6 Conclusão

Este trabalho teve como objetivo avaliar a eficácia da WT na redução de ruído em imagens de RM, por meio da implementação de rotinas em Python e da aplicação de diferentes famílias wavelet e métodos de limiarização.

Os resultados mostraram que o **hard thresholding** proporcionou maiores ganhos de SNR, enquanto o **soft thresholding** preservou melhor detalhes estruturais das imagens. Entre as famílias testadas, **db2**, **sym2** e **coif1** apresentaram desempenho consistente, ao passo que a **Haar** mostrou-se menos adequada para a tarefa.


Esses achados reforçam o potencial das wavelets como ferramenta de *denoising* em imagens médicas, embora a análise tenha se limitado à métrica de SNR e a um modelo de ruído simplificado. Como desdobramentos futuros, recomenda-se a exploração de técnicas adaptativas de limiarização (como SureShrink e BayesShrink), o uso de decomposições alternativas (como *wavelet packets*) e a adoção de métricas perceptuais de qualidade de imagem, como o SSIM, que podem oferecer uma avaliação mais completa da eficácia dos métodos.

MRI 15 dB




(a) Imagem corrompida ($\text{SNR} = 15$ dB).

WT db2 L1 15dB - Antes




(b) Coeficientes da WT-2D (db2), nível 1, antes do thresholding.

WT db2 L2 15dB - Antes




(c) Coeficientes da WT-2D (db2), nível 2, antes do thresholding.

Rec db2 hard 15dB




(d) Imagem reconstruída (hard thresholding).

Rec db2 soft 15dB




(e) Imagem reconstruída (soft thresholding).


Figura 16: Caso-teste (15 dB), decomposição pela WT-2D (db2) antes do thresholding, e resultado dos diferentes thresholdings.




(f) Coeficientes da WT-2D (db2) após hard thresholding — nível 1.



(g) Coeficientes da WT-2D (db2) após hard thresholding — nível 2.



(h) Coeficientes da WT-2D (db2) após soft thresholding — nível 1.



(i) Coeficientes da WT-2D (db2) após soft thresholding — nível 2.

Figura 16: Comparação visual entre WT-2D de hard e soft thresholding (continuação).

Referências Bibliográficas

- [1] Python Software Foundation. Python: A dynamic, open source programming language. <https://www.python.org/>, 2023.
- [2] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt, Ralf Gommers, Pauli Virtanen, David Cournapeau, Eric Wieser, Julian Taylor, Sebastian Berg, Nathaniel J. Smith, et al. Array programming with NumPy. *Nature*, 585(7825):357–362, 2020. doi: 10.1038/s41586-020-2649-2.
- [3] John D. Hunter. Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, 9(3):90–95, 2007. doi: 10.1109/MCSE.2007.55.
- [4] Gregory R. Lee, Ralf Gommers, Filip Waselewski, Kai Wohlfahrt, and Aaron O’Leary. PyWavelets: A python package for wavelet analysis. In *Journal of Open Source Software*, volume 4, page 1237, 2019. doi: 10.21105/joss.01237.
- [5] John C. Gore. Principles and practice of functional MRI of the human brain. *Journal of Clinical Investigation*, 112(1):4–9, July 2003. doi: 10.1172/JCI19010.
- [6] Santiago Aja-Fernández and Gonzalo Vegas-Sánchez-Ferrero. *Statistical Analysis of Noise in MRI: Modeling, Filtering and Estimation*. Springer, Switzerland, 2016. ISBN 978-3-319-82000-6.
- [7] Maria Aparecida Fernandes Almeida. Filtragem digital de sinais biomédicos. Master’s thesis, Universidade Federal de Santa Catarina, Florianópolis, SC, Brasil, 1997.
- [8] Kanhaiya Kumar, Lokesh Varshney, A. Ambikapathy, Kajol Malik, Kumari Vanshika, and Aryan Vats. Image denoising by wavelet based thresholding method. In *International Conference on Advance Computing and Ingenious Technology in Engineering Science (ACITES)*, Greater Noida, India, 2022. In press.
- [9] Márcio Henrique T. de Lima, Moisés Ferreira S. Domingues, and Rogério Menezes Batista. Conversor: um dispositivo que recebe um sinal analógico transformando-o em digital. *Bolsista de Valor: Revista de divulgação do Projeto Universidade Petrobras e IF Fluminense*, 1:407–409, 2010.
- [10] Rafael C. Gonzalez and Richard E. Woods. *Digital Image Processing*. Prentice Hall, Upper Saddle River, NJ, USA, 3rd edition, 2008. ISBN 9780131687288.
- [11] Ricardo Tokio Higuti and Cláudio Kitano. *Sinais e Sistemas*. Departamento de Engenharia Elétrica, UNESP – Faculdade de Engenharia de Ilha

- Solteira, 2003. URL https://www.feis.unesp.br/Home/departamentos/engenhariaeletrica/optoeletronica/sinais_e_sistemas.pdf. Versão 1.1 (original 1997); ISA Julho/2003.
- [12] Sebastián Rivera, Francisco Albiach, and Julio Esquivel. Linear signal processing methods and decay ratio estimation. In *Linear and Non-Linear Stability Analysis in Boiling Water Reactors*, chapter 6. Elsevier, Oxford, 2019. doi: 10.1016/B978-0-08-102445-4.00006-0.
 - [13] Panchamkumar D. Shukla. Complex wavelet transforms and their applications. M.phil. thesis, University of Strathclyde, Glasgow, United Kingdom, 2003.
 - [14] Rodrigo Capobianco Guido. Effectively interpreting discrete wavelet transformed signals. *IEEE Signal Processing Magazine*, 34(3):89–100, 2017. doi: 10.1109/MSP.2017.2652807.
 - [15] Joseana Macêdo Fachine. A transformada de fourier e suas aplicações. Ciclo de Seminários Técnicos, Grupo PET Computação, DSC/CEEI/UFCG, 2010. Disponível em: https://www.dsc.ufcg.edu.br/~pet/ciclo_seminarios/tecnicos/2010/TransformadaDeFourier.pdf.
 - [16] Rodrigo Capobianco Guido. Wavelets behind the scenes: Practical aspects, insights, and perspectives. *Physics Reports*, 985:1–23, 2022. doi: 10.1016/j.physrep.2022.08.001.
 - [17] Stéphane G. Mallat. *A Wavelet Tour of Signal Processing*. Academic Press, San Diego, 2 edition, 1999. ISBN 978-0-12-466606-1.
 - [18] Christian Kroos, Takaaki Kuratate, and Eric Vatikiotis-Bateson. Video-based face motion measurement. *Journal of Phonetics*, 30(3):569–590, 2002. doi: 10.1006/jpho.2002.0164.
 - [19] Yury Polyanskiy and Yihong Wu. *Information Theory: From Coding to Learning*. Cambridge University Press, Cambridge, 1 edition, 2023. ISBN 9781108832908.
 - [20] Jesse Connell. Wavelet transforms and signal processing, December 2014. URL <https://www.reddy.us/files/wavelets.pdf>. Accessed: 2025-09-14.
 - [21] Ananias Pereira Neto and Fabrício J. B. Barros. Noise reduction in brain magnetic resonance imaging using adaptive wavelet thresholding based on linear prediction factor. *Frontiers in Neuroscience*, 18:1516514, 2025. doi: 10.3389/fnins.2024.1516514.

- [22] David L. Donoho and Iain M. Johnstone. Ideal spatial adaptation by wavelet shrinkage. *Biometrika*, 81(3):425–455, 1994. doi: 10.1093/biomet/81.3.425.
- [23] Wes McKinney. Data structures for statistical computing in python. In Stéfan van der Walt and Jarrod Millman, editors, *Proceedings of the 9th Python in Science Conference*, pages 51–56, 2010.
- [24] Michael L. Waskom. Seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60):3021, 2021. doi: 10.21105/joss.03021.
- [25] Leon Paixão Menezes. Desenvolvimento de filtros baseados em transformadas wavelet para espectroscopia por ressonância magnética. Master’s thesis, Universidade de São Paulo – IFSC, São Carlos, SP, Brasil, 2017. URL https://www.teses.usp.br/teses/disponiveis/76/76132/tde-07032018-095408/publico/LeonPaixaoMenezes_ME_original.pdf. Dissertação de Mestrado.