

## Processamento de Imagens por Ressonância Magnética utilizando Transformada Wavelet

Thiago Oliveira dos Santos

Fernando Fernandes Paiva

Instituto de Física de São Carlos – Universidade de São Paulo

toszerodois@usp.br

### Objetivos

Este projeto visa avaliar estratégias de processamento de imagens de Ressonância Magnética (RM) com a Transformada Wavelet (WT). Busca-se analisar a eficácia de diferentes famílias wavelet e técnicas de limiarização na redução de ruído, preservando bordas e detalhes estruturais. Os objetivos específicos incluem: (i) determinar a família wavelet mais adequada para supressão de ruído; (ii) investigar a eficácia de técnicas de thresholding hard/soft; e (iii) relacionar parâmetros da WT com a qualidade final das imagens, medida pela Razão Sinal-Ruído (SNR).

### Métodos e Procedimentos

Inicialmente, foi realizado nivelamento teórico sobre a Transformada Wavelet discreta (DWT) (Guido, 2022) e técnicas de limiarização (Donoho & Johnstone, 1994; Pereira & Barros, 2025). Esse estudo guiou a implementação dos pipelines (Menezes, 2017) e a leitura crítica dos resultados subsequentes.

Foi utilizada uma imagem de RM em tons de cinza (PGM) como caso-teste, processada em Python com NumPy, Matplotlib e PyWavelets (Harris et al., 2020; Hunter, 2007; Lee et al., 2019).

A imagem foi corrompida com ruído gaussiano controlado por SNR alvo (7,5-20 dB), e em




Figura 1: (a) – Gráfico de dispersão que compara SNR de entrada a SNR de saída. (b) Boxplot do ganho de SNR por família.

seguida aplicou-se DWT-2D de nível 2 com as famílias Haar, Daubechies-2 (db2), Symlet-2 (sym2) e Coiflet-1 (coif1). O limiar universal do VisuShrink ( $\lambda = \sigma\sqrt{2 \log N}$ ) foi calculado para as imagens corrompidas, a partir do qual são avaliados hard e soft thresholding.

Após a limiarização, as imagens foram reconstruídas, e comparadas de acordo com o SNR de saída, e os resultados foram registrados em uma planilha, que foi analisada através de um boxplot e um gráfico de dispersão.

## Resultados

Os gráficos gerados podem ser vistos na Figura 1. Eles indicam que todas as famílias tiveram um desempenho semelhante quanto ao ganho de SNR, exceto pela família haar. Também é possível notar que o hard thresholding teve maior eficácia para o ganho de SNR que o soft thresholding.

Além disso, dadas as inclinações das retas formadas pelos pontos do gráfico de dispersão, é possível notar que existe um limite de SNR de entrada, a partir do qual os métodos deixam de ter eficácia.

Outro ponto analisado, qualitativamente dessa vez, foi o fato de que sinais de ruídos mais baixos (7,5; 10) tiveram perdas significativas de resolução, um indicador de que o thresholding está atuando também nos coeficientes de sinal.

## Conclusões

Os resultados demonstram que a Transformada Wavelet 2D é uma ferramenta eficiente para redução de ruído em imagens de RM. O hard thresholding se mostrou mais vantajoso, elevando significativamente a SNR; entretanto, é preciso destacar que o soft thresholding normalmente não atinge os mesmos resultados do hard thresholding, dado que os coeficientes que não foram zerados diminuem a intensidade final do sinal, o que indica que outras métricas de qualidades podem ser utilizadas. Entre as famílias

avaliadas, Haar destacou-se pelo pior resultado, o que pode não ser inesperado devido a sua simplicidade.

Esses resultados reforçam o potencial das wavelets em denoising de RM e apontam para a necessidade de investigar métodos adaptativos mais avançados, como SureShrink e BayesShrink.

Declaro não haver conflito de interesses.

Thiago Oliveira dos Santos concebeu o estudo, implementou os códigos em Python, conduziu os experimentos e analisou os resultados. Fernando Fernandes Paiva orientou o projeto, contribuiu com a interpretação dos resultados e revisou o manuscrito.

## Referências

- GUIDO, Rodrigo Capobianco. **Wavelets behind the scenes: practical aspects, insights, and perspectives**. *Physics Reports*, v. **985**, p. 1–23, 2022.
- MENEZES, Leon Paixão. **Desenvolvimento de filtros baseados em transformadas wavelet para espectroscopia por Ressonância Magnética**. Dissertação (Mestrado em Ciências) — IFSC/USP, São Carlos, 2017.
- DONOHU, David L.; JOHNSTONE, Iain M. **Ideal spatial adaptation by wavelet shrinkage**. *Biometrika*, v. **81**, n. 3, p. 425–455, 1994.
- PEREIRA NETO, Ananias; BARROS, Fabrício J. B. **Noise reduction in brain magnetic resonance imaging using adaptive wavelet thresholding based on linear prediction factor**. *Frontiers in Neuroscience*, v. **18**, art. 1516514, 2025.
- HARRIS, Charles R. *et al.* **Array programming with NumPy**. *Nature*, v. **585**, p. 357–362, 2020.
- HUNTER, John D. **Matplotlib: A 2D Graphics Environment**. *Computing in Science & Engineering*, v. **9**, n. 3, p. 90–95, 2007.
- LEE, Gregory R. *et al.* **PyWavelets: A Python package for wavelet analysis**. *Journal of Open Source Software*, v. **4**, n. 36, p. 1237, 2019.